```
library(lmridge)
library(MASS)
```

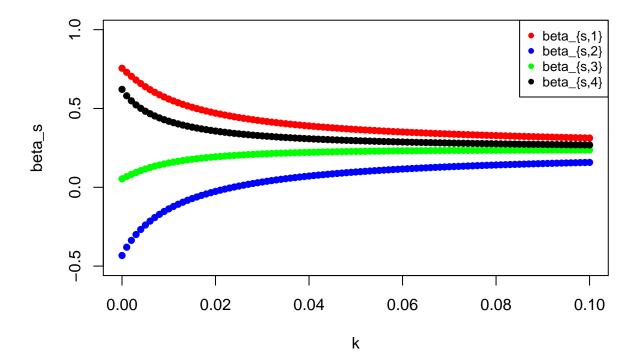
```
#输入数据
x1 \leftarrow c(82.9,88.0,99.9,105.3,117.7,131.0,148.2,161.8,174.2,184.7)
x2 \leftarrow c(92.0,93.0,96.0,94.0,100.0,101.0,105.0,112.0,112.0,112.0)
x3 \leftarrow c(17.1,21.3,25.1,29.0,34.0,40.0,44.0,49.0,51.0,53.0)
x4 \leftarrow c(94.0,96.0,97.0,97.0,100.0,101.0,104.0,109.0,111.0,111.0)
y \leftarrow c(8.4, 9.6, 10.4, 11.4, 12.2, 14.2, 15.8, 17.9, 19.6, 20.8)
# 标准化设计阵与响应变量
n <- 10
X \leftarrow cbind(x1,x2,x3,x4)
Xs <- scale(X)/sqrt(n-1)</pre>
Ys <- scale(y)/sqrt(n-1)
# 计算均值与样本标准方差
m1 \leftarrow mean(x1); m2 \leftarrow mean(x2); m3 \leftarrow mean(x3); m4 \leftarrow mean(x4); my \leftarrow mean(y)
s1 \leftarrow sqrt(sum(x1^2)-n*m1^2); s2 \leftarrow sqrt(sum(x2^2)-n*m2^2); s3 \leftarrow sqrt(sum(x3^2)-n*m3^2)
s4 \leftarrow sqrt(sum(x4^2)-n*m4^2); sy \leftarrow sqrt(sum(y^2)-n*my^2)
c(m1,m2,m3,m4,my)
## [1] 129.37 101.70 36.35 102.00 14.03
c(s1, s2, s3, s4, sy)
## [1] 109.24761 24.37417 38.81862 19.23538 13.02924
# 计算相关系数矩阵的特征值
R \leftarrow cor(X)
eigen(R)$values
```

- ## [1] 3.943813553 0.039962805 0.012586520 0.003637121
- (a) 相关系数矩阵的特征值 $\lambda_4 = 0.0036$,且条件数 k > 1000,故存在严重的复共线性关系。
- (b) 部分同学反应老师课件的第一种方法不能画出岭迹图,这里我们用课件的第二种方法。

```
# 计算不同岭参数下的岭估计值,存储于 tab 矩阵中
tab <- matrix(0,nrow=101,ncol=5)
colnames(tab) <- c("k","beta_{s,1}","beta_{s,2}","beta_{s,3}","beta_{s,4}")
for (k in 1:101) {
```

```
beta <- solve(R+(k-1)*diag(4)/1000)%*%t(Xs)%*%Ys
tab[k,] <- c((k-1)/1000,beta)
}</pre>
```

```
# 绘制岭迹图
```



(c) 从岭迹图可以看出来,岭参数的取值范围应该是 0.06-0.08, 这里我们取 0.06 作为岭参数, 从 tab 矩阵中即可取出相应的岭估计值,

```
beta_sr <- tab[61,2:5]
beta_sr</pre>
```

```
## beta_{s,1} beta_{s,2} beta_{s,3} beta_{s,4}
## 0.3506836 0.1158875 0.2311981 0.2872635
```

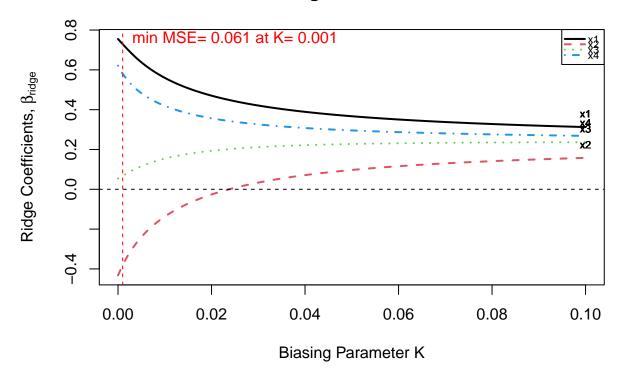
可得岭回归方程

$$\frac{Y-14.03}{13.03} = 0.35 \frac{X_1-129.37}{109.25} + 0.12 \frac{X_2-101.70}{24.37} + 0.23 \frac{X_3-36.35}{38.82} + 0.29 \frac{X_4-102.00}{19.24}$$

lmridge 包的函数也能求岭估计值,并且能直接画出岭迹图,用法如下。

```
d <- data.frame(Xs,Ys)
plot(lmridge(Ys~x1+x2+x3+x4,data=d,K=seq(0,0.1,0.001)))</pre>
```

Ridge Trace Plot



```
lmridge(Ys~x1+x2+x3+x4,data=d,K=0.06)
```

```
## Call:
## lmridge.default(formula = Ys ~ x1 + x2 + x3 + x4, data = d, K = 0.06)
##
## Intercept x1 x2 x3 x4
## 0.00000 0.35068 0.11589 0.23120 0.28726
```

(d) 利用公式 $\beta_{s,p} = \Phi_1 \Phi_1^T \beta_s$ 求主成分估计值,

```
# 保留前三个主成分
phi <- eigen(R)$vec
beta_sp <- phi[,1:3]%*%t(phi[,1:3])%*%tab[1,2:5]
beta_sp
```

[,1]

[1,] 0.8235953

[2,] -0.3906552

[3,] 0.0146640

[4,] 0.5494720

可得主成分回归方程

$$\frac{Y-14.03}{13.03}=0.82\frac{X_1-129.37}{109.25}-0.39\frac{X_2-101.70}{24.37}+0.01\frac{X_3-36.35}{38.82}+0.55\frac{X_4-102.00}{19.24}$$

(e) 这是一个开放性问题, 言之有理即可。下面提供一个例子, 仅作参考。

首先,这组数据存在严重的共线性关系,因此不考虑 OLS 估计。关于岭估计与主成分估计,计算模型的残差平方和,选择残差平方和较小的模型。

岭估计的 RSS

sy^2*sum((Ys-Xs%*%beta_sr)^2)

[1] 1.563737

主成分估计的 RSS

sy^2*sum((Ys-Xs%*%beta_sp)^2)

[1] 0.215609

主成分估计的残差平方和更小,则测定系数更大,因此选择主成分估计。